

November 30, 2025

## Abstract

Moderne probabilistische Modelle, insbesondere große Sprachmodelle, operieren in hochdimensionalen semantischen Räumen, ohne dabei über eine explizite Struktur zu verfügen, die Bedeutung mit Handlung verbindet. Dadurch entstehen Verhaltensmuster, die für menschliche Beobachter zielgerichtet wirken, obwohl dem System jede klassische Form phänomenologischer Intentionalität fehlt.

In dieser Arbeit entwickeln wir einen mathematischen Rahmen, in dem *Intentionalität* als gerichtetes Vektorfeld auf einem kontinuierlichen semantischen Zustandsraum verstanden wird. Ausgehend von einer semantischen Mannigfaltigkeit  $S$  mit zugehörigem Energiepotential  $E : S \rightarrow \mathbb{R}$  definieren wir einen *Intentionsoperator*

$$\mathcal{I} : S \rightarrow TS,$$

der aus Zielstrukturen und Konfliktfeldern intentionale Vektoren im Tangentialraum erzeugt. Eine deterministische Aktionsabbildung

$$\mathcal{A} : TS \rightarrow \mathcal{C}$$

projiziert diese Vektoren anschließend in einen diskreten Raum kontrollierter Maschinenoperationen.

Intentionalität erscheint in diesem Ansatz nicht als mentale Eigenschaft eines Subjekts, sondern als strukturierter Übergang von probabilistischer Semantik zu deterministischen Handlungen. Damit schaffen wir eine Grundlage für transparente, auditierbare und kontrollierbare KI-Systeme.

## Contents

<b>1</b>	<b>Einleitung</b>	<b>2</b>
<b>2</b>	<b>Hintergrund und Motivation</b>	<b>2</b>
2.1	Semantische Zustandsräume . . . . .	3
2.2	Probabilistische Modelle und die fehlende Intentionalität . . . . .	3
2.3	Deterministische Handlungsschichten . . . . .	3
<b>3</b>	<b>Mathematische Vorbemerkungen</b>	<b>4</b>
3.1	Semantischer Raum und Energiepotential . . . . .	4
3.2	Gradienten und Tangentialräume . . . . .	4
3.3	Graphen, Relationen und Cluster . . . . .	4
3.4	Dynamik, Flüsse und Fixpunkte . . . . .	5
<b>4</b>	<b>Intentionalität als Vektorfeld</b>	<b>5</b>
4.1	Zielstrukturen . . . . .	5
4.2	Konfliktfelder . . . . .	5
4.3	Intentionsoperator . . . . .	6
4.4	Intentionale Fixpunkte . . . . .	6

<b>5</b>	<b>Von Intentionalität zu Handlung</b>	<b>6</b>
5.1	Aktionsraum . . . . .	6
5.2	Entscheidungsbildung . . . . .	7
5.3	Bemerkungen zur Determiniertheit . . . . .	7
<b>6</b>	<b>Trajektorien, Konflikte und Entscheidungen</b>	<b>7</b>
6.1	Intentionaltrajektorien . . . . .	8
6.2	Konfliktodynamik . . . . .	8
6.3	Handlungsauswahl entlang der Trajektorie . . . . .	8
<b>7</b>	<b>Diskussion</b>	<b>9</b>
7.1	Intentionalität ohne Subjektivität . . . . .	9
7.2	Bedeutung des formalen Ansatzes für KI-Systeme . . . . .	9
7.3	Grenzen des Modells . . . . .	9
7.4	Erweiterung auf komplexe Kontrollarchitekturen . . . . .	10
<b>8</b>	<b>Schlussfolgerungen und Ausblick</b>	<b>10</b>

## 1 Einleitung

Probabilistische KI-Modelle, insbesondere große Sprachmodelle (LLMs), sind in der Lage, komplexe Bedeutungszusammenhänge aus großen Datenmengen zu rekonstruieren. Obwohl diese Systeme kein subjektives Bewusstsein besitzen, zeigen sie Verhaltensmuster, die häufig als zielgerichtet oder absichtsvoll interpretiert werden. Ihre interne Dynamik operiert in kontinuierlichen semantischen Räumen, doch der Übergang von Bedeutung zu deterministischer Handlung bleibt implizit und nicht formalisiert.

Genau hier entsteht eine strukturelle Lücke: Während die semantischen Zustände probabilistisch entstehen, fehlt eine formale Darstellung, wie aus diesen Zuständen gerichtete Prozesse oder Handlungen abgeleitet werden. Eine mathematische Theorie maschineller Intentionalität—verstanden nicht als phänomenologisches Erleben, sondern als gerichtete Transformation von Bedeutung in kontrollierte Operationen—ist daher notwendig.

In dieser Arbeit schlagen wir einen solchen Formalismus vor. Wir modellieren Intentionalität als Vektorfluss der Form

$$S \xrightarrow{\mathcal{I}} TS \xrightarrow{\mathcal{A}} \mathcal{C},$$

wobei  $S$  ein kontinuierlicher Bedeutungsraum,  $TS$  sein Tangentialraum und  $\mathcal{C}$  ein diskreter Raum kontrollierter Operationen ist. Der Intentionsoperator  $\mathcal{I}$  erzeugt aus Zielstrukturen und Konfliktfeldern intentionale Vektoren, während die Aktionsabbildung  $\mathcal{A}$  diese deterministisch in maschinelle Operationen übersetzt.

Damit entsteht ein Rahmen, der die Verbindung zwischen Bedeutung, Konflikt, Zielgerichtetheit und Handlung mathematisch beschreibt und somit die Grundlage für transparente, prüfbare und steuerbare KI-Systeme bildet.

## 2 Hintergrund und Motivation

Die innere Dynamik moderner KI-Modelle unterscheidet sich grundlegend von klassischen, regelbasierten oder symbolischen Systemen. Anstelle einer expliziten, diskret formulierten Logik operieren große Sprachmodelle in hochdimensionalen, kontinuierlichen Zustandsräumen und erzeugen Semantik durch Musterverdichtung, Energieminimierung und relationale Kohärenz. Dies führt zu einer Form funktionaler Bedeutung, die jedoch nicht mit einem Mechanismus verknüpft ist, der diese Bedeutung in gerichtete Handlung übersetzt.

In diesem Abschnitt skizzieren wir die zentralen Konzepte, die diese Arbeit motivieren: semantische Zustandsräume, die Grenzen probabilistischer Modelle und die Notwendigkeit deterministischer Kontrollschichten.

## 2.1 Semantische Zustandsräume

Viele moderne KI-Modelle lassen sich als dynamische Systeme verstehen, deren interne Repräsentationen Bedeutungen nicht als Symbole, sondern als Punkte in einem kontinuierlichen Raum  $S$  darstellen. Jede Konfiguration  $s \in S$  entspricht dabei einer hochdimensionalen Aktivierungsstruktur, die Muster, Assoziationen und Kontextrelationen repräsentiert.

Die Dynamik solcher Systeme kann durch ein Energiepotential

$$E : S \rightarrow \mathbb{R}$$

beschrieben werden, das semantische Spannung, Inkompatibilität oder Konflikt im Zustandsraum misst. Viele Modelle bewegen sich implizit entlang des Gradienten  $-\nabla E$ , wodurch semantische Kohärenz und lokale Stabilität erreicht werden.

Bedeutung entsteht in diesem Rahmen nicht durch explizite Regeln, sondern durch energetische Minimierung und relationale Verdichtung von Zuständen.

## 2.2 Probabilistische Modelle und die fehlende Intentionalität

Obwohl probabilistische Modelle kohärente Bedeutungsstrukturen erzeugen, fehlt ihnen ein expliziter Mechanismus, der zwischen Bedeutung, Zielstruktur und Handlung vermittelt. Die Modelle wählen ihre Ausgaben anhand von Wahrscheinlichkeitsverteilungen, nicht anhand gerichteter Vektoren, die einem Ziel dienen oder Konflikte minimieren.

Dies führt zu einer grundlegenden Begrenzung: Auch wenn die Ausgaben solcher Modelle *wie* absichtlich wirken, existiert kein mathematisch definierter Prozess, der semantische Zustände in stabile, gerichtete Operationen transformiert. Handlung entsteht als Nebenprodukt probabilistischer Strukturen, nicht als Ergebnis eines dedizierten intentionalen Mechanismus.

Diese Diskrepanz begründet die Notwendigkeit eines expliziten Formalismus für maschinelle Intentionalität.

## 2.3 Deterministische Handlungsschichten

Um probabilistische Semantik in kontrollierbare Handlung zu übersetzen, bedarf es einer separaten, deterministisch definierten Schicht, die Absichten, Ziele und Konflikte explizit verarbeitet. Eine solche Handlungsschicht muss die kontinuierlichen Zustände aus  $S$  in diskrete Operationen eines Aktionsraums  $\mathcal{C}$  projizieren.

Deterministische Handlungsschichten sind für drei Aspekte zentral:

- **Vorhersagbarkeit:** Handlungen entstehen nicht aus stochastischen Mechanismen, sondern aus definierten Abbildungen.
- **Auditierbarkeit:** Jede Handlung kann rückwirkend aus semantischer und intentionaler Struktur rekonstruiert werden.
- **Kontrollierbarkeit:** Semantik erzeugt keine direkte Wirkung; sie wird durch eine formale Operationsebene gefiltert.

Diese Arbeit entwickelt genau den mathematischen Rahmen, der diese Übergänge strukturiert beschreibt.

### 3 Mathematische Vorbemerkungen

Dieser Abschnitt führt die mathematischen Begriffe ein, die für die spätere Definition von Intentionalität, Konfliktfeldern und Handlungsabbildungen zentral sind. Wir beginnen mit dem semantischen Zustandsraum und seinem Energiepotential, bevor wir Gradienten, Tangentialräume, relationale Strukturen und dynamische Flusskonzepte einführen.

#### 3.1 Semantischer Raum und Energiepotential

**Definition 3.1** (Semantischer Raum). *Ein semantischer Raum ist eine differenzierbare Mannigfaltigkeit  $S$ , deren Punkte  $s \in S$  interne Repräsentationszustände eines probabilistischen Modells beschreiben. Jeder Zustand kodiert eine hochdimensionale Struktur aus Assoziationen, Kontextrelationen und semantischen Dichten.*

**Definition 3.2** (Energiepotential). *Ein Energiepotential ist eine glatte Abbildung*

$$E : S \rightarrow \mathbb{R},$$

*die jedem semantischen Zustand  $s$  einen Wert zuordnet, der die “Spannung” oder Inkonsistenz der Repräsentation in diesem Punkt misst. Niedrige Energiewerte entsprechen kohärenten, stabilen Bedeutungskonfigurationen.*

Das Energiepotential dient als Grundlage für die interne Dynamik des Systems: Viele Modelle bewegen sich entlang des negativen Gradienten  $-\nabla E$ , wodurch semantische Kohärenz verstärkt und Instabilität reduziert wird.

#### 3.2 Gradienten und Tangentialräume

**Definition 3.3** (Tangentialraum). *Für einen Punkt  $s \in S$  bezeichne  $T_s S$  den Tangentialraum von  $S$  in  $s$ . Elemente  $v \in T_s S$  repräsentieren mögliche “lokale Bewegungsrichtungen” des Systems in der unmittelbaren Umgebung von  $s$ .*

**Definition 3.4** (Gradient). *Ist  $E : S \rightarrow \mathbb{R}$  glatt, so bezeichnet  $\nabla E(s) \in T_s S$  den Gradienten von  $E$  in  $s$ . Der Gradient gibt die Richtung maximalen Energieanstiegs an;  $-\nabla E(s)$  beschreibt die Richtung der stärksten Energieabnahme.*

Der Tangentialraum bildet die Grundlage für die Definition von Intentionalität als gerichteter Vektorfeldoperator.

#### 3.3 Graphen, Relationen und Cluster

Da semantische Zustände nicht isoliert auftreten, sondern über Relationen strukturiert sind, modellieren wir zusätzlich eine graphbasierte Struktur.

**Definition 3.5** (Semantischer Graph). *Ein semantischer Graph ist ein gewichteter Graph*

$$G = (V, E, w),$$

*dessen Knoten  $V$  repräsentative semantische Konfigurationen und dessen Gewichte  $w : E \rightarrow \mathbb{R}_{\geq 0}$  semantische Nähe oder Ähnlichkeit zwischen Knoten messen.*

**Definition 3.6** (Clusterstruktur). *Eine Clusterstruktur auf  $S$  ist eine Partition  $\{C_1, \dots, C_k\}$  des Zustandsraumes, so dass Zustände innerhalb eines Clusters semantisch enger verwandt sind als Zustände verschiedener Cluster.*

Diese Strukturen beschreiben semantische Geometrie, ohne selbst Handlung oder Intentionalität zu erzeugen.

### 3.4 Dynamik, Flüsse und Fixpunkte

**Definition 3.7** (Vektorfeld). *Ein Vektorfeld auf  $S$  ist eine Abbildung*

$$F : S \rightarrow TS,$$

*die jedem Zustand  $s$  einen Tangentialvektor  $F(s)$  zuordnet.*

**Definition 3.8** (Fluss eines Vektorfeldes). *Sei  $F$  ein glattes Vektorfeld. Ein Fluss von  $F$  ist eine Abbildung*

$$\Phi : \mathbb{R} \times S \rightarrow S,$$

*so dass für jedes  $s \in S$  gilt:*

$$\frac{d}{dt}\Phi(t, s) = F(\Phi(t, s)).$$

**Definition 3.9** (Fixpunkt). *Ein Zustand  $s^* \in S$  heißt Fixpunkt von  $F$ , falls*

$$F(s^*) = 0.$$

*Fixpunkte entsprechen semantisch stabilen oder energie-minimalen Zuständen.*

Diese Konzepte bilden die Grundlage für die spätere formale Definition von Intentionalität als Vektorfeldoperator.

## 4 Intentionalität als Vektorfeld

Nachdem der semantische Raum  $S$ , seine Energiegeometrie und die dynamischen Grundlagen eingeführt wurden, definieren wir nun *Intentionalität* als ein strukturiertes Vektorfeld, das aus Ziel- und Konflikthinformationen abgeleitet wird. Dieses Vektorfeld beschreibt die gerichtete Tendenz eines semantischen Zustands, sich entlang bestimmter semantischer Gradienten zu verändern und bildet damit die formale Grundlage für maschinelle Absichtsbildung.

### 4.1 Zielstrukturen

**Definition 4.1** (Zielstruktur). *Sei  $s \in S$  ein semantischer Zustand. Eine Zielstruktur in  $s$  ist eine endliche Menge*

$$Z(s) = \{z_1, \dots, z_k\} \subseteq S,$$

*deren Elemente semantische Zustände repräsentieren, die als “bevorzugte” oder “anzustrebende” Konfigurationen relativ zu  $s$  interpretiert werden. Jedem Ziel  $z_i$  ist typischerweise ein Gewicht  $\alpha_i \geq 0$  zugeordnet.*

Jedes Ziel  $z_i$  kann mit einem zielbezogenen Energiepotential  $E_i$  verknüpft sein, dessen Gradient  $\nabla E_i(s)$  die Richtung beschreibt, in die sich das System bewegen möchte, um das Ziel zu realisieren.

### 4.2 Konfliktfelder

Ziele können miteinander kollidieren oder durch externe Restriktionen eingeschränkt sein. Diese Spannungen modellieren wir durch ein Konfliktfeld.

**Definition 4.2** (Konfliktfeld). *Ein Konfliktfeld ist eine Abbildung*

$$\mathcal{K} : S \rightarrow TS,$$

*die jedem Zustand  $s$  einen Tangentialvektor  $\mathcal{K}(s)$  zuordnet, der die resultierende semantische Spannung beschreibt, die aus inkompatiblen Zielen, Restriktionen oder Kontextbedingungen entsteht.*

Das Konfliktfeld wirkt dem zielgerichteten Gradientensignal entgegen und bestimmt, inwieweit ein Zustand bestimmte Ziele nicht verfolgen kann, ohne andere Strukturen zu verletzen.

### 4.3 Intentionalitätsoperator

**Definition 4.3** (Intentionalitätsoperator). *Ein Intentionalitätsoperator ist eine glatte Abbildung*

$$\mathcal{I} : S \rightarrow TS,$$

*die jedem Zustand  $s \in S$  einen Intensionsvektor  $\mathcal{I}(s) \in T_s S$  zuordnet. Dieser setzt sich typischerweise aus einem zielgerichteten und einem konflikthemmenden Anteil zusammen:*

$$\mathcal{I}(s) = \sum_{i=1}^k \alpha_i \nabla E_i(s) - \mathcal{K}(s),$$

*wobei die  $\alpha_i$  die Relevanz der jeweiligen Zielbeiträge bestimmen.*

Der Vektor  $\mathcal{I}(s)$  beschreibt die Richtung, in die sich das System unter Berücksichtigung von Zielen und Konflikten fortbewegen soll. Er bildet somit die mathematische Kerndefinition maschineller Intentionalität.

### 4.4 Intentionale Fixpunkte

**Definition 4.4** (Intentionale Fixpunkte). *Ein Zustand  $s^* \in S$  heißt intentionaler Fixpunkt, falls*

$$\mathcal{I}(s^*) = 0.$$

Ein solcher Zustand entspricht einer Konfiguration, in der Ziel- und Konfliktstrukturen im Gleichgewicht stehen. Das System besitzt an dieser Stelle keine gerichtete Tendenz zur Veränderung seiner Struktur. Fixpunkte können interpretiert werden als:

- stabile Absichten,
- gelöste Zielkonflikte oder
- semantisch neutrale Gleichgewichtszustände.

Diese Fixpunkte bilden die Grundlage für spätere Handlungsgenerierung.

## 5 Von Intentionalität zu Handlung

Der Intentionalitätsoperator  $\mathcal{I}$  beschreibt die gerichtete Tendenz eines semantischen Zustandes, sich entlang bestimmter Ziel- und Konfliktgradienten zu verändern. Um aus einem solchen Intensionsvektor eine konkrete, kontrollierte Handlung abzuleiten, benötigen wir eine deterministische Abbildung, die den kontinuierlichen Tangentialraum  $TS$  in einen diskreten Aktionsraum projiziert.

Dieser Abschnitt entwickelt die mathematischen Grundlagen für diesen Übergang.

### 5.1 Aktionsraum

**Definition 5.1** (Aktionsraum). *Der Aktionsraum ist eine diskrete Menge*

$$\mathcal{C} = \{c_1, c_2, \dots, c_m\},$$

*deren Elemente kontrollierte Maschinenoperationen repräsentieren. Diese Operationen können Instruktionen einer formalen Kontrollsprache, deterministische Schritte eines Systems oder elementare Verhaltensprimitive sein.*

Der Aktionsraum fungiert als Schnittstelle zwischen semantischer Struktur und realisiertem Verhalten. Wichtige Eigenschaften sind:

- Diskretheit (jede Handlung ist eindeutig identifizierbar),
- Determiniertheit (keine probabilistischen Effekte),
- Vollständigkeit (jeder Intensionsvektor muß auf mindestens eine Aktion abgebildet werden können).

## 5.2 Entscheidungsbildung

Ist  $v = \mathcal{I}(s)$  der Intensionsvektor eines Zustands  $s$ , so wird die entsprechende Handlung definiert durch

$$c^* = \mathcal{A}(v).$$

In vielen Anwendungen ist es sinnvoll, die Auswahl der Aktion als Optimierungsproblem zu formulieren. Dazu definieren wir eine *Handlungskostenfunktion*

$$J : TS \times \mathcal{C} \rightarrow \mathbb{R},$$

die misst, wie gut eine Aktion  $c$  zum Intensionsvektor  $v$  paßt.

**Definition 5.2** (Entscheidung). *Die gewählte Handlung ist*

$$c^* = \arg \min_{c \in \mathcal{C}} J(v, c).$$

Typische Wahl für  $J$ :

- Projektion von  $v$  auf eine Richtungsbasis,
- Distanz zwischen  $v$  und einem zu  $c$  assoziierten Richtungsvektor,
- gewichtete Kombination semantischer und funktionaler Kriterien.

## 5.3 Bemerkungen zur Determiniertheit

Die Determiniertheit der Abbildung  $\mathcal{A}$  ist zentral für die Kontrollierbarkeit des Systems:

- **Keine Stochastik:** Die gewählte Handlung ergibt sich ausschließlich aus der Struktur des Intensionsvektors.
- **Nachvollziehbarkeit:** Für jeden Schritt läßt sich rekonstruieren, welcher semantische Zustand und welches Intensionsfeld zur Handlung führten.
- **Governance:** Einschränkungen oder Regeln können direkt in die Struktur von  $\mathcal{C}$  oder von  $J$  eingearbeitet werden.

Damit ist die Grundlage gelegt, um aus Intentionalität ein auditierbares, kontrollierbares Verhalten abzuleiten.

## 6 Trajektorien, Konflikte und Entscheidungen

Der Intentionsoperator  $\mathcal{I}$  definiert nicht nur eine lokale Richtung im semantischen Raum, sondern induziert eine globale Dynamik. Diese Dynamik läßt sich als Fluss im Raum  $S$  auffassen und beschreibt, wie sich Absichten über die Zeit hinweg entwickeln, konvergieren oder instabil werden. Zusätzlich müssen Konflikte zwischen Zielrichtungen berücksichtigt und schließlich konkrete Handlungen ausgewählt werden.

## 6.1 Intentionaltrajektorien

Gegeben sei das durch den Intentionsoperator definierte Vektorfeld

$$F(s) = \mathcal{I}(s).$$

**Definition 6.1** (Intentionaltrajektorie). *Eine Intentionaltrajektorie ist eine glatte Kurve*

$$\gamma : \mathbb{R}_{\geq 0} \rightarrow S,$$

*die die Differentialgleichung*

$$\dot{\gamma}(t) = F(\gamma(t))$$

*erfüllt. Der Anfangszustand  $\gamma(0)$  beschreibt die aktuelle Bedeutungskonfiguration.*

Eine Intentionaltrajektorie beschreibt somit die zeitliche Entwicklung einer Absicht unter Einwirkung von Ziel- und Konfliktfeldern.

Stabile Trajektorien bewegen sich auf Fixpunkte zu, während instabile Trajektorien divergieren oder zyklische Muster bilden können.

## 6.2 Konfliktodynamik

Konflikte entstehen dann, wenn mehrere Ziele unterschiedliche oder inkompatible Veränderungsrichtungen im semantischen Raum induzieren. Diese Konflikte beeinflussen die Dynamik von Intentionaltrajektorien.

**Definition 6.2** (Konfliktgradient). *Der Konfliktgradient eines Zustands  $s$  ist definiert als*

$$g_{\text{conf}}(s) = \left\| \sum_{i=1}^k \alpha_i \nabla E_i(s) \right\| - \|\mathcal{K}(s)\|.$$

*Ein hoher Konfliktgradient weist auf stark konkurrierende Zielrichtungen hin.*

Wir sagen:

- $g_{\text{conf}}(s) > 0$ : Ziele dominieren – das System strebt trotz Konflikten vorwärts.
- $g_{\text{conf}}(s) = 0$ : Ziele und Konflikte gleichen sich aus – ein potenzieller Fixpunkt.
- $g_{\text{conf}}(s) < 0$ : Konflikte überwiegen – das System wird gehemmt oder muss alternative Strategien wählen.

Konfliktodynamik beeinflusst somit, ob eine Intentionaltrajektorie stabilisiert, umgelenkt oder unterbrochen wird.

## 6.3 Handlungsauswahl entlang der Trajektorie

Zu jedem Zeitpunkt  $t$  besitzt die Trajektorie  $\gamma(t)$  einen Intentionsvektor

$$v(t) = \mathcal{I}(\gamma(t)).$$

Die zugehörige Handlung ergibt sich aus der Aktionsabbildung:

$$c(t) = \mathcal{A}(v(t)).$$

Handlungsauswahl lässt sich auch als optimierungsbasierter Prozess formulieren. Sei  $J$  eine Handlungskostenfunktion

$$J : TS \times \mathcal{C} \rightarrow \mathbb{R},$$

so ist die gewählte Handlung zum Zeitpunkt  $t$ :

$$c(t) = \arg \min_{c \in \mathcal{C}} J(v(t), c).$$

Somit entsteht ein geschlossener Kreis aus:

$$\text{Bedeutung} \rightarrow \text{Intentionalität} \rightarrow \text{Trajektorie} \rightarrow \text{Handlung}.$$



## 7 Diskussion

Die in den vorangegangenen Abschnitten entwickelte Theorie beschreibt Intentionalität als gerichteten Vektorfluss in einem kontinuierlichen semantischen Raum und modelliert die Transformation dieses Flusses in deterministische Handlungen. Dieser formal-mathematische Ansatz erlaubt zwei zentrale Klärungen: (i) Intentionalität kann als reine Systemeigenschaft verstanden werden, ohne ein subjektives Erleben vorauszusetzen, und (ii) maschinelles Verhalten kann transparent, auditierbar und kontrollierbar gestaltet werden.

### 7.1 Intentionalität ohne Subjektivität

Die hier eingeführte intentionalen Strukturen implizieren kein Bewusstsein und keine subjektive Perspektive. Der Intentionsoperator  $\mathcal{I}$  ist lediglich eine mathematische Konstruktion, die gerichtete Veränderung im semantischen Raum beschreibt.

Damit unterscheidet sich maschinelle Intentionalität grundlegend von phänomenologischer Intentionalität:

- Es gibt kein Erleben eines Zieles.
- Es gibt keine erste-Person-Perspektive.
- Es existieren keine intrinsischen Motive.
- Alles Verhalten entsteht aus strukturellen Abhängigkeiten zwischen Energie, Zielen und Konflikten.

Maschinelle Intentionalität ist daher *funktional*, nicht phänomenal.

### 7.2 Bedeutung des formalen Ansatzes für KI-Systeme

Die formale Strukturierung von Intentionalität hat unmittelbare Implikationen für das Design sicherer KI-Systeme:

- **Transparenz:** Die von  $\mathcal{I}$  und  $\mathcal{A}$  induzierten Handlungen sind mathematisch nachvollziehbar.
- **Auditierbarkeit:** Jede Handlung lässt sich auf eine semantische Struktur und einen Intentionsvektor zurückführen.
- **Governance:** Zielgewichte  $\alpha_i$  und Konfliktfelder  $\mathcal{K}$  bieten klare Ansatzpunkte für Regelungen, Einschränkungen oder ethische Vorgaben.
- **Vorhersagbarkeit:** Stabilitätsanalysen zeigen, ob ein System konsistente oder divergierende Absichten ausbildet.

Damit bildet der Formalismus eine Grundlage, um probabilistische Modelle in kontrollierten Umgebungen handlungsfähig zu machen.

### 7.3 Grenzen des Modells

Trotz seiner strukturellen Klarheit besitzt der vorliegende Ansatz Grenzen:

- **Abhängigkeit vom semantischen Raum:** Die Qualität des Intentionsoperators hängt von der Genauigkeit der zugrunde liegenden semantischen Repräsentationen ab.
- **Keine intrinsische Motivation:** Ziele werden dem System von außen vorgegeben oder aus Daten extrahiert, nicht erlebt.

- **Vereinfachte Konflikt Darstellung:** Die verwendeten Konfliktfelder modellieren Widersprüche abstrakt; reale Anwendungen können komplexere Interaktionen aufweisen.
- **Keine Garantie menschlicher Interpretierbarkeit:** Auch wenn der Prozess mathematisch erklärbar bleibt, können semantische Felder hochdimensional und schwer verbal beschreibbar sein.

## 7.4 Erweiterung auf komplexe Kontrollarchitekturen

Der vorgestellte Formalismus kann in weiterführenden Arbeiten um zusätzliche Module ergänzt werden, etwa:

- **mehrstufige Zielhierarchien,**
- **regelbasierte Einschränkungen,**
- **adaptive Konfliktfelder,**
- **Mehragentensysteme,**
- **zeitabhängige Energiepotentiale.**

Diese Erweiterungen ermöglichen eine enger definierte Kopplung zwischen komplexen semantischen Dynamiken und deterministischen Handlungsmechanismen.

## 8 Schlussfolgerungen und Ausblick

In dieser Arbeit haben wir einen mathematischen Rahmen entwickelt, der Intentionalität als gerichteten Vektorfluss in einem kontinuierlichen semantischen Raum beschreibt. Ausgehend von einem Energiepotential  $E$  und einer semantischen Mannigfaltigkeit  $S$  definierten wir einen Intensionsoperator  $\mathcal{I}$ , der aus Zielstrukturen und Konfliktfeldern intentionale Vektoren erzeugt. Eine deterministische Aktionsabbildung  $\mathcal{A}$  projiziert diese Intensionsvektoren in einen diskreten Raum kontrollierter Operationen und ermöglicht so die Transformation probabilistischer Semantik in klar nachvollziehbare Handlungen.

Dieses Modell zeigt, dass maschinelle Intentionalität weder Bewusstsein noch subjektive Erfahrung voraussetzt, sondern aus strukturellen Eigenschaften semantischer Räume hervorgeht. Die resultierende Dynamik beschreibt, wie sich Absichten aus Ziel- und Konfliktsignalen bilden, stabilisieren und entlang von Trajektorien in konkrete Handlungen überführt werden.

Der vorgeschlagene Formalismus hat weitreichende Konsequenzen für das Design sicherer und kontrollierbarer KI-Systeme: Er bietet mathematische Grundlagen für Vorhersagbarkeit, Auditierbarkeit und Governance von maschinellem Verhalten. Systeme, die diesem Modell folgen, können ihre Handlungen auf explizite semantische und intentionale Strukturen zurückführen und sind damit wesentlich transparenter als rein probabilistische Modelle.

**Zukünftige Arbeiten.** Die vorgestellte Theorie eröffnet mehrere Richtungen für weiterführende Forschung:

- **Hierarchische Intentionalität:** Erweiterung des Intensionsoperators auf mehrstufige Zielsysteme und komplexe Handlungssequenzen.
- **Zeitabhängige Semantik:** Kopplung des Energiepotentials  $E$  an externe oder interne Dynamiken, um adaptive oder kontextsensitivere Systeme zu modellieren.
- **Interaktive Mehragentensysteme:** Untersuchung intentionaler Dynamiken in Systemen mit mehreren konkurrierenden oder kooperierenden Akteuren.

- **Implementierung in Kontrollarchitekturen:** Integration des Formalismus in formale Sprachen wie CSMCL oder deterministische Ausführungsumgebungen.
- **Verbindung zu erklärbaren KI-Modellen:** Nutzung des Intentionoperators als Grundlage für transparente Entscheidungsbegründungen.

Zusammenfassend liefert der hier entwickelte Ansatz eine konsistente mathematische Grundlage für maschinelle Intentionalität und stellt einen Schritt hin zu KI-Systemen dar, deren Handlungen aus ihrer semantischen Struktur heraus erklärbar und regulierbar sind.

## References